

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2544

**PROCJENA FAKTORA U FAKTORSKIM
MODELIMA POVRATA IMOVINA ZASNOVANA
NA STROJNOM UČENJU**

Damjan Crnković

Zagreb, lipanj, 2026.

ZAVRŠNI ZADATAK br. 2544

Pristupnik: **Damjan Crnković (0036557629)**

Studij: Elektrotehnika i informacijska tehnologija i Računarstvo

Modul: Računarstvo

Mentor: doc. dr. sc. Stjepan Begušić

Zadatak: **Procjena faktora u faktorskim modelima povrata imovina zasnovana na strojnom učenju**

Opis zadatka:

U ovom završnom radu razmatra se problem procjene faktora u faktorskim modelima financijskih povrata. U sklopu rada potrebno je prvo analizirati klasične pristupe procjeni faktora, uključujući metode zasnovane na glavnim komponentama i regresijskim postupcima. Nadalje, potrebno je razviti i implementirati pristupe zasnovane na metodama strojnog učenja za otkrivanje i procjenu latentnih faktora koristeći karakteristike imovina te odabrane makroekonomske varijable. Razvijene modele potrebno je empirijski ispitati na povijesnim tržišnim podacima, analizirati njihovu sposobnost objašnjavanja presjeka povrata te usporediti performanse s klasičnim faktorskim modelima. Posebnu pažnju potrebno je posvetiti interpretaciji procijenjenih faktora i njihovoj ulozi u objašnjavanju sistematskih izvora rizika.

Rok za predaju rada: 12. lipnja 2026.

*Zahvaljujem svojoj obitelji na podršci tijekom studiranja te mentoru na savjetima i
pomoći pri izradi rada.*

Sadržaj

1. Uvod	3
2. Faktorski modeli povrata imovina	5
2.1. Povrati i povrat iznad bezrizične stope	5
2.2. Definicija i pretpostavke faktorskog modela	6
2.2.1. Od koreliranih varijabli do faktora	6
2.2.2. Opća definicija modela	7
2.2.3. Sistematski i idiosinkratski dio	8
2.2.4. Pretpostavke modela	8
2.3. Faktorski modeli u vrednovanju imovine	9
2.4. Primjeri faktorskih modela: CAPM i Fama-French	10
2.4.1. Capital Asset Pricing Model (CAPM)	10
2.4.2. Fama-French trofaktorski model	11
2.5. Procjena faktorskog modela	12
2.5.1. Linearna regresija i metoda najmanjih kvadrata	12
2.5.2. Procjena faktorskih izloženosti	13
2.6. Metode procjene premija na rizik	14
2.6.1. Procjena povijesnom sredinom	14
2.6.2. Procjena s poznatim budućim faktorima (engl. <i>oracle</i>)	15
2.6.3. Fama-MacBeth regresija	15
2.7. Procjena premija dubokim učenjem	16
2.7.1. Povratne mreže i LSTM	16
2.7.2. Procjena premija LSTM mrežom	18
3. Podaci	19

3.1. Izvori i razdoblje uzorka	19
3.2. Promatrana imovina	20
3.3. Faktori i bezrizična stopa	20
3.4. Shillerov omjer cijene i zarade	22
3.5. Obrada	24
4. Rezultati	26
4.1. Klizni vremenski prozor	26
4.2. Mjere uspješnosti	27
4.3. Rezultati klasičnih metoda procjene	28
4.4. Procjena dubokim učenjem	29
4.5. Usporedba metoda i rasprava	33
5. Zaključak	36
Literatura	38
Izjava o korištenju umjetne inteligencije	40
Sažetak	41
Abstract	42

1. Uvod

Predviđanje povrata financijske imovine prvo je pitanje koje se nameće većini sudionika na financijskim tržištima. Povrati se na prvi pogled ponašaju kao slučajna varijabla: cijene dionica i drugih oblika imovine mijenjaju se naizgled bez ikakve pravilnosti. Ipak, jedan dio tih kretanja moguće je objasniti zajedničkim izvorima rizika, što je upravo temeljna ideja faktorskih modela. Oni pretpostavljaju da povrat pojedine imovine nije nezavisna slučajna varijabla, već linearna kombinacija njezine izloženosti nekolicini zajedničkih faktora rizika koji djeluju na tržište u cijelosti. Svaki takav faktor nosi premiju na rizik, odnosno prosječnu nagradu koju investitor dugoročno ostvaruje preuzimanjem izloženosti tom riziku. Imovina koja je nekom riziku izložena jače trebala bi stoga u prosjeku donositi i veći očekivani povrat, pa se po toj pretpostavci razlike u prosječnim povratima različitih imovina svode na razlike u njihovoj izloženosti sistematskim izvorima rizika.

Primjena faktorskog modela zahtijeva procjenu dva tipa veličina. Prva je izloženost pojedine imovine svakom od faktora, a druga premija na rizik koju svaki faktor nosi, to jest prosječni povrat koji izloženost tom faktoru donosi. Procjena premija pokazuje se znatno težim zadatkom. Budući da je svaki faktor i sam povrat određenog dijela tržišta, procjena njegove premije zapravo je predviđanje budućeg kretanja tog dijela tržišta, što je samo po sebi vrlo zahtjevan zadatak. Njemu se često pristupa jednostavno: premija se procijeni kao povijesni prosjek povrata određenog faktora. Takva je procjena, međutim, često nepouzdana. Financijski su podaci izrazito šumoviti, a premije nisu konstantne već se mijenjaju kroz vrijeme, pa povijesni prosjek lako daje nestabilnu i pristranu sliku buduće premije. Modelu izgrađenom na takvoj procjeni zato je teško dobro generalizirati, jer nestabilna premija loše opisuje povrate izvan razdoblja na kojem je procijenjena.

Klasični pristupi procjeni faktorskih modela uglavnom se oslanjaju na regresijske

postupke. Ovaj rad ostaje unutar tog okvira, ali se usmjerava na njegov najosjetljiviji dio, procjenu premija na rizik. Polazi od standardiziranog Fama-French modela (Fama i French, 1993), a temeljno pitanje kojim se bavi jest mogu li metode strojnog učenja dati bolju procjenu premija od klasičnih pristupa. Središnja je ideja umjesto jednostavnog prosjeka upotrijebiti povratnu ćeliju s dugoročnom memorijom (LSTM). Arhitektura takvog modela prigodna je radu s vremenskim nizovima, pa mreža može prepoznati obrasce u kretanju faktora koje srednja vrijednost zanemaruje. Uz povijesne vrijednosti samih faktora, mreža kao ulaz prima i odabrane makroekonomske varijable, koje mogu poslužiti kao prediktori premija te iz kojih model može naučiti ovisnosti koje u samim povratima faktora nisu vidljive. Dobivene procjene zatim se uspoređuju s povijesnim prosjekom i Fama-MacBeth regresijom kao klasičnim pristupima, ali i s idealnom procjenom (engl. *oracle*) koja može poslužiti kao teorijska gornja granica izvedbe.

Strojno te duboko učenje posljednjih je godina pronašlo široku i uspješnu primjenu u empirijskom vrednovanju imovine (Feng et al., 2023). Te metode prepoznaju složene i nelinearne obrasce u velikim i šumovitim financijskim podacima, koje linearni pristupi često ne uspijevaju objasniti, pa su prirodan kandidat za zadatak procjene faktorskih premija. Velika ekspresivnost tih modela, međutim, nosi i rizik prenaučenosti (engl. *overfitting*). Dovoljno složen model uz dobru prilagodbu povijesnim podacima počinje opisivati i šum u njima, pa njegova točnost na podacima korištenima pri učenju ne govori ništa o stvarnoj kvaliteti procjene. Uspješnost metode stoga se ocjenjuje njezinom izvedbom na podacima koje model tijekom učenja nije vidio, dakle sposobnošću generalizacije.

Cilj rada je na stvarnim tržišnim podacima procijeniti i međusobno usporediti opisane metode procjene faktorskih premija te ocijeniti koliko uspješno objašnjavaju razlike u prosječnim povratima među imovinama. Naglasak je pritom na izvanuzorčnoj (engl. *out-of-sample*) izvedbi: na predviđanju povrata iz razdoblja koja metodama pri procjeni nisu bila dostupna. Rad je organiziran kako slijedi. Drugo poglavlje iznosi teorijsku podlogu faktorskih modela i metoda procjene premija na rizik, treće opisuje korištene podatke i njihovu obradu, dok četvrto prikazuje i analizira dobivene rezultate. Na kraju se izvode glavni zaključci i navode mogući smjerovi daljnjega istraživanja.

2. Faktorski modeli povrata imovina

2.1. Povrati i povrat iznad bezrizične stope

Vlasništvo nad financijskom imovinom nosi pravo na buduće novčane tokove. Tipičan je primjer dionica: ona predstavlja udio u vlasništvu nad poduzećem, a vlasniku donosi dio njegove dobiti i mogućnost zarade kroz porast cijene odnosno vrijednosti. Osim pojedinačnih dionica važni su i portfelji, odnosno skupovi više dionica ili nekih drugih oblika imovine.

Najvažnije svojstvo imovine je povrat koji donosi vlasniku. Povrat mjeri relativnu promjenu vrijednosti imovine kroz jedno vremensko razdoblje, dakle koliko je vlasnik zaradio ili izgubio u odnosu na uloženo. Označimo li cijenu imovine i na kraju razdoblja t s $P_{i,t}$, a cijenu na kraju prethodnog razdoblja s $P_{i,t-1}$, povrat imovine definiramo kao

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}. \quad (2.1)$$

Brojnik je promjena cijene ostvarena u razdoblju, a dijeljenjem početnom cijenom ta se promjena izražava relativno, pa povrat ne ovisi o apsolutnoj razini cijene i usporediv je među različitim imovinama. Vrijednost imovine pratimo u diskretnim vremenskim trenucima, pri čemu je duljina razdoblja između dvaju uzastopnih trenutaka proizvoljna. U ovom radu to će razdoblje biti jedan mjesec, pa indeks t označava redni mjesec promatranja.

U realnom okruženju kapital se rijetko alocira u jednu imovinu. On se raspoređuje između više njih. Takav skup imovina nazivamo *portfeljem*. Sastavimo li ga od N imovina, svakoj pridružujemo *težinu* w_i koja govori koliki dio ukupno uloženog kapitala otpada na imovinu i . Težine su nenegativne i njihov zbroj jednak je jedan, $\sum_{i=1}^N w_i = 1$. Bu-

dući da je povrat omjer promjene vrijednosti i uloženog iznosa, povrat portfelja jednak je težinskom prosjeku povrata njegovih sastavnica (Cochrane, 2005, pogl. 1),

$$R_{p,t} = \sum_{i=1}^N w_i R_{i,t}. \quad (2.2)$$

Posebnu ulogu ima imovina koja nije izložena tržišnom riziku, pa je njezin povrat unaprijed poznat i ne ovisi o kretanju ostatka tržišta. Taj povrat nazivamo *bezrizičnom stopom povrata* i označavamo s $R_{f,t}$. Kao njezina mjera uzima se prinos kratkoročnih državnih trezorskih zapisa, koji se smatraju jednim od najsigurnijih ulaganja.

Oduzmemo li od povrata imovine bezrizičnu stopu istoga razdoblja, dobivamo veličinu koju nazivamo *povratom iznad bezrizične stope* (Cochrane, 2005, pogl. 1). Budući da se cijeli rad bavi isključivo tim povratom, oznaka $R_{i,t}$ u nastavku podrazumijevat će izraz $R_{i,t} - R_{f,t}$, dakle povrat iznad bezrizične stope.

Bezrizična stopa predstavlja oportunitetni trošak ulaganja: prinos koji bismo ostvarili i bez izlaganja ikakvom riziku. Tek onaj dio povrata koji je nadmašuje je stvarna nagrada za preuzeti rizik. Pozitivan očekivani povrat iznad bezrizične stope govori da se izloženost riziku u prosjeku isplati, a negativan da imovina preuzeti rizik ne nagrađuje.

Upravo je taj dio povrata u središtu faktorskih modela. Oni ne nastoje objasniti ukupne povrate, nego onaj dio povrata koji predstavlja nagradu za izloženost sistematskim izvorima rizika. Zbog toga se sve veličine u nastavku rada, ako nije drukčije naznačeno, odnose na povrate iznad bezrizične stope, a očekivani povrat pojedine imovine iznad bezrizične stope označavamo s $E(R_{i,t})$.

2.2. Definicija i pretpostavke faktorskog modela

2.2.1. Od koreliranih varijabli do faktora

Faktorski model potječe iz multivarijatne statistike, u kojoj se strukturu povezanosti velikog broja varijabli nastoji opisati malim brojem skrivenih, neopaženih varijabli (Johnson i Wichern, 2013). Polazi od jednostavnog opažanja. Ako se varijable mogu grupirati tako da su unutar grupe međusobno snažno povezane, a slabo povezane s varijablama iz dru-

gih grupa, prirodno je pretpostaviti da iza svake grupe stoji jedna zajednička, neopažena varijabla, *faktor*, odgovorna za to zajedničko kretanje. Faktorska analiza nastoji potvrditi postojanje takve strukture i mnoštvo pojedinačnih varijabli zamijeniti faktorima.

Faktori su najčešće prikriveni te se procjenjuju iz podataka. U ovom radu faktore, naprotiv, zadajemo unaprijed (odjeljak 2.4.2.). U nastavku ovog odjeljka najprije definiramo modela i njegove pretpostavke, a zatim izdvajamo one koje su relevantne za pristup koji koristimo.

2.2.2. Opća definicija modela

Promatramo opaženi slučajni vektor $X = (X_1, \dots, X_p)^\top$ s p komponenti i očekivanjem $\mu = E(X)$. Faktorski model pretpostavlja da je X linearno ovisan o malom broju $m < p$ neopaženih slučajnih veličina $F_1, \dots, F_m$, koje nazivamo *zajedničkim faktorima*, te o p dodatnih izvora varijacije $\varepsilon_1, \dots, \varepsilon_p$, koje nazivamo *pogreškama* ili *specifičnim faktorima* (Johnson i Wichern, 2013). Po komponentama model glasi

$$\begin{aligned} X_1 - \mu_1 &= \ell_{11}F_1 + \ell_{12}F_2 + \dots + \ell_{1m}F_m + \varepsilon_1, \\ &\vdots \\ X_p - \mu_p &= \ell_{p1}F_1 + \ell_{p2}F_2 + \dots + \ell_{pm}F_m + \varepsilon_p, \end{aligned} \quad (2.3)$$

odnosno, u matričnom zapisu,

$$X - \mu = \underset{(p \times 1)}{L} \underset{(p \times m)}{F} + \underset{(p \times 1)}{\varepsilon} \quad (2.4)$$

(Johnson i Wichern, 2013, jedn. 9-1, 9-2).

Koeficijent ℓ_{ij} naziva se *opterećenje* (engl. *loading*) i -te varijable na j -ti faktor, pa je $L = [\ell_{ij}] \in \mathbb{R}^{p \times m}$ *matrica faktorskih opterećenja*. Njezin i -ti redak označavamo $\beta_i^\top = (\ell_{i1}, \dots, \ell_{im})$ i on sadrži izloženosti i -te varijable svim faktorima. Specifični faktor ε_i vezan je isključivo uz i -tu varijablu.

Iako matrični zapis (2.4) podsjeća na linearni regresijski model, među njima postoji bitna razlika: u regresiji su varijable opažene, dok su ovdje neopaženi i opterećenja L i faktori F . Zato se model ne može procijeniti običnom regresijom, nego tek uz dodatne

pretpostavke o F i ε koje navodimo u nastavku (Johnson i Wichern, 2013).

2.2.3. Sistematski i idiosinkratski dio

Izraz $X_i - \mu_i = \beta_i^\top F + \varepsilon_i$ dijelimo na 2 cjeline. Prva, $\beta_i^\top F$, naziva se *sistematskim dijelom*: čine ga isti faktori F za sve varijable, a među varijablama se razlikuje samo po opterećenjima β_i . Taj dio nosi *zajedničku* varijaciju cijelom skupu i izvor je povezanosti među varijablama. Drugi, ε_i , naziva se *idiosinkratskim* ili *specifičnim dijelom*: vezan je isključivo uz i -tu varijablu i nosi onu varijaciju koju zajednički faktori ne objašnjavaju.

Vektor opterećenja β_i mjeri osjetljivost i -te varijable na faktore: veća apsolutna vrijednost ℓ_{ij} označava jaču izloženost faktoru j . Rastav razdvaja sistematski rizik $\beta_i^\top F$, zajednički svim varijablama, od idiosinkratskog rizika ε_i , specifičnog za pojedinu varijablu. Idiosinkratski rizik se uklanja raspršivanjem ulaganja; ta je razlika temelj vrednovanja u odjeljku 2.3.

2.2.4. Pretpostavke modela

Da bi rastav na zajednički i specifični dio bio smislen, na faktore i pogreške postavljamo sljedeće pretpostavke (Johnson i Wichern, 2013):

- model je linearan u faktorima, kako je zapisano u (2.4);
- pogreške su centrirane, $E(\varepsilon) = 0$;
- faktori i pogreške su nekorelirani, $\text{Cov}(F, \varepsilon) = 0$;
- pogreške različitih komponenata su međusobno nekorelirane, tj. $\text{Cov}(\varepsilon) = \Psi$ je dijagonalna matrica.

Posljednja je pretpostavka srž faktorskog modela: ona govori da svu povezanost među komponentama vektora X nose isključivo zajednički faktori, dok specifične pogreške ne dijele varijaciju ni međusobno ni s faktorima.

2.3. Faktorski modeli u vrednovanju imovine

Opću formulaciju iz prethodnog odjeljka sada primjenjujemo na povrate imovina. Model više ne zapisujemo kao $X - \mu$, već kao višak povrata pojedine imovine: u vrednovanju imovine faktori su opaženi i imaju očekivanja različita od 0 te ih interpretiramo kao premije na rizik. U zapisu se sada pojavljuju odsječak α_i i očekivanje faktora $\lambda = E(F)$, kojih u početnoj definiciji nije bilo.

Pretpostavka o nekoreliranosti idiosinkratskih pogrešaka, izražena dijagonalnošću matrice Ψ , ima ključnu posljedicu za vrednovanje imovine. U portfelju sastavljenom od velikog broja imovina specifične pogreške su međusobno nekorelirane, pa se pri zbrajanju velikim dijelom međusobno poništavaju; zajednička izloženost faktorima, naprotiv, ostaje. Idiosinkratski rizik investitor stoga može gotovo u potpunosti ukloniti raspršivanjem ulaganja, bez dodatnog troška, pa mu tržište ne pridjeljuje nagradu (Cochrane, 2005, pogl. 1). Nagrađuje se isključivo sistematski rizik, odnosno izloženost zajedničkim faktorima.

Promotrimo sada očekivani povrat pojedine imovine. Faktorski model u povratu iznad bezrizične stope glasi

$$R_i = \alpha_i + \beta_i^\top F + \varepsilon_i, \quad (2.5)$$

pri čemu je $\beta_i^\top F$ sistematski dio, a ε_i idiosinkratska pogreška s očekivanjem nula. Uzmemo li očekivanje objiju strana jednadžbe (2.5), idiosinkratski dio iščezava i ostaje

$$E(R_i) = \alpha_i + \beta_i^\top \lambda, \quad \lambda = E(F). \quad (2.6)$$

Vektor λ sadrži očekivanja faktora, a svaku njegovu komponentu interpretiramo kao *premiju na rizik*, prosječnu nagradu za jediničnu izloženost pripadnom faktorom. Umnožak $\beta_i^\top \lambda$ stoga je onaj dio očekivanog povrata koji potječe od izloženosti imovine sistematskim rizicima.

Preostali član α_i je dio očekivanog povrata koji se *ne* može pripisati izloženosti faktorima, takozvana pogreška u vrednovanju (engl. *pricing error*). Ako faktorski model u cijelosti objašnjava povrat imovine, taj član iščezava. Uz restrikciju $\alpha_i = 0$ izraz (2.6)

svodi se na

$$E(R_i) = \beta_i^\top \lambda, \quad (2.7)$$

pa razlike u očekivanim povratima među imovinama u potpunosti određuju razlike u njihovim izloženostima β_i i zajedničkim premijama λ .

Jednadžba (2.7) sažima cilj vrednovanja imovine faktorskim modelom: objasniti očekivane povrate pomoću dva tipa veličina, izloženosti β_i specifičnih za svaku imovinu i premija λ zajedničkih svim imovinama. Procjena premija λ je osjetljivija i, kako je istaknuto u uvodu, predstavlja središnji problem kojim se ovaj rad bavi. Nastavak je posvećen procjeni λ .

2.4. Primjeri faktorskih modela: CAPM i Fama-French

Utvdili smo da ako su povrati vođeni nekolicinom zajedničkih izvora rizika, očekivani povrati ovise o izloženostima tim faktorima i o njihovim premijama. Preostaje ključno empirijsko pitanje: koje faktore odabrati. Povijesno se odgovor razvijao od najjednostavnijeg modela s jednim, tržišnim faktorom prema modelima s više faktora. U nastavku najprije iznosimo CAPM, a zatim Fama-French trofaktorski model koji koristimo u ostatku rada.

2.4.1. Capital Asset Pricing Model (CAPM)

Najjednostavniji i povijesno prvi model ovoga tipa jest model vrednovanja kapitalne imovine (engl. *Capital Asset Pricing Model*, CAPM) (Sharpe, 1964). On pretpostavlja postojanje samo jednog zajedničkog izvora rizika, tržišta kao cjeline, pa je riječ o faktorskom modelu s $m = 1$. Pripadni faktor je *tržišni povrat iznad bezrizične stope*, $MKT = R_M - R_f$, gdje je R_M povrat *tržišnog portfelja*, portfelja koji obuhvaća svu rizičnu imovinu s težinom koja ovisi o tržišnoj kapitalizaciji. U stvarnosti se taj portfelj aproksimira nekim od širokih tržišnih indeksa. Tržišni faktor time predstavlja zajedničko kretanje cijelog tržišta, odnosno sistematski rizik kojemu su, u različitoj mjeri, izložene sve imovine.

Uvrstimo li taj jedini faktor u opći izraz (2.7), očekivani povrat imovine postaje pro-

porcionalan njezinoj tržišnoj izloženosti,

$$E(R_i) = \beta_i^{\text{MKT}} \lambda_{\text{MKT}}, \quad (2.8)$$

pri čemu je β_i^{MKT} osjetljivost imovine na tržišni faktor, a λ_{MKT} tržišna premija na rizik. CAPM time tvrdi da se sve razlike u očekivanim povratima među imovinama svode na razlike u jednoj veličini, tržišnoj izloženosti β_i^{MKT} .

2.4.2. Fama-French trofaktorski model

Iako konceptualno smislen i snažan, CAPM ne uspijeva objasniti cijeli skup prosječnih povrata. Pokazalo se da prosječni povrati ovise i o obilježjima koja tržišni faktor ne obuhvaća: kompanije male tržišne kapitalizacije te kompanije s visokim omjerom knjigovodstvene i tržišne vrijednosti u prosjeku donose veće povrate nego što bi CAPM predividio (Fama i French, 1993). Da bi se te pravilnosti obuhvatile, Fama i French (Fama i French, 1993) proširuju model s dva dodatna faktora.

Uz tržišni faktor MKT, model uvodi:

- SMB faktor (engl. *small minus big*), razliku prosječnih povrata portfelja kompanija male i velike tržišne kapitalizacije;
- HML faktor (engl. *high minus low*), razliku prosječnih povrata portfelja kompanija s visokim i niskim omjerom knjigovodstvene i tržišne vrijednosti.

Faktori SMB i HML stoga su povrati portfelja s nultim ulaganjem (duga pozicija u jednoj skupini poduzeća, kratka u drugoj), dok je tržišni faktor već izražen kao povrat iznad bezrizične stope. Trofaktorski model za imovinu i tada glasi

$$R_i = \alpha_i + \beta_i^{\text{MKT}} \text{MKT} + \beta_i^{\text{SMB}} \text{SMB} + \beta_i^{\text{HML}} \text{HML} + \varepsilon_i, \quad (2.9)$$

što je poseban slučaj općeg modela (2.5) uz $F = (\text{MKT}, \text{SMB}, \text{HML})^\top$.

Sva tri faktora su povrati konkretnih portfelja, što je njihovo važno svojstvo. Kako je pokazano u odjeljku 2.3., premija na rizik faktora jednaka je njegovu očekivanju, $\lambda_k = E(F_k)$. Budući da je svaki faktor sam po sebi povrat, njegova se premija svodi na očeki-

vani povrat pripadnog portfelja, pa se i procjena premija λ svodi na procjenu očekivanih povrata triju faktora. Tom je problemu posvećen ostatak rada.

Naglašavamo da je Fama-French model samo *jedan* od mogućih izbora faktora; ovdje ga uzimamo kao standardiziran okvir unutar kojega proučavamo procjenu premija, a ne kao predmet vlastite analize. Pojedinih konstrukcije faktora i izvor podataka iznosimo u poglavlju 3.

2.5. Procjena faktorskog modela

Dosad smo faktorski model i njegove posebne slučajeve samo definirali. Da bismo ga primijenili na stvarne podatke, moramo mu procijeniti parametre. Razlikujemo dvije vrste veličina: faktorske izloženosti β_i , specifične za svaku imovinu, i premije na rizik λ , zajedničke svim imovinama. Obje se procjenjuju iz opaženih povrata, a temeljna je metoda za to linearna regresija metodom najmanjih kvadrata.

2.5.1. Linearna regresija i metoda najmanjih kvadrata

Linearna regresija opisuje vezu jedne zavisne varijable s jednom ili više objašnjavajućih varijabli. Neka je y zavisna varijabla, a $x = (x_1, \dots, x_k)^\top$ vektor od k objašnjavajućih varijabli; pretpostavlja se da je y približno linearna funkcija od x ,

$$y_t = b_0 + b_1 x_{t1} + \dots + b_k x_{tk} + u_t, \quad t = 1, \dots, n, \quad (2.10)$$

gdje su $b_0, \dots, b_k$ nepoznati koeficijenti, u_t pogreška (odstupanje opažanja od linearne veze), a n broj opažanja. Složimo li opažanja zavisne varijable u vektor $y \in \mathbb{R}^n$, a regresore u *matricu dizajna* $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ čiji je prvi stupac jediničan (za odsječak b_0), model sažeto glasi

$$y = \mathbf{X}b + u, \quad b = (b_0, b_1, \dots, b_k)^\top. \quad (2.11)$$

Koeficijente procjenjujemo *metodom najmanjih kvadrata* (engl. *ordinary least squares*, OLS) (Hastie et al., 2009, pogl. 3): biramo one vrijednosti koje minimiziraju zbroj kvadrata reziduala, to jest zbroj kvadrata odstupanja opaženih vrijednosti od onih koje

model predviđa,

$$\hat{b} = \arg \min_b \sum_{t=1}^n (y_t - b_0 - b_1 x_{t1} - \dots - b_k x_{tk})^2. \quad (2.12)$$

Uz pretpostavku da je matrica $\mathbf{X}$ punog ranga, taj minimizacijski problem ima jedinstveno rješenje u zatvorenoj formi,

$$\hat{b} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top y. \quad (2.13)$$

Geometrijski, $\hat{b}$ određuje linearnu funkciju najbližu opaženim podacima u smislu najmanjega zbroja kvadrata odstupanja. Taj isti postupak koristimo čak dva puta: u odjeljku 2.5.2. za procjenu faktorskih izloženosti β_i (regresijom povrata na faktore), te u sklopu Fama-MacBeth metode za procjenu premija λ (cross-sectional regresijom).

2.5.2. Procjena faktorskih izloženosti

U apstraktnoj postavci faktorskog modela faktori su neopaženi: njihove vrijednosti nije moguće izravno mjeriti, nego se moraju procijeniti iz podataka zajedno s opterećenjima. Kod Fama-French modela situacija se ponešto razlikuje. Faktori su zadani kao povrati konkretnih portfelja, pa su njihove vrijednosti u svakom razdoblju izravno dostupne iz tržišnih podataka. Faktorske izloženosti β_i stoga možemo procijeniti izravno linearnom regresijom povrata imovine iznad bezrizične stope na faktore.

Promotrimo imovinu i i niz njezinih povrata iznad bezrizične stope $R_{i,t}$ kroz T uzastopnih razdoblja. Prema modelu (2.5), svaki je povrat iznad bezrizične stope linearna funkcija vrijednosti faktora u trenutku t ,

$$R_{i,t} = \alpha_i + \beta_i^\top F_t + \varepsilon_{i,t}, \quad t = 1, \dots, T, \quad (2.14)$$

gdje je $F_t = (\text{MKT}_t, \text{SMB}_t, \text{HML}_t)^\top$ vektor faktora u razdoblju t . To je upravo linearni regresijski model (2.11): zavisna je varijabla povrat imovine iznad bezrizične stope, regresori su faktori, odsječak je α_i , a nagibi su tražene izloženosti β_i . Primjenom metode najmanjih kvadrata (2.13) dobivamo procjene $\hat{\alpha}_i$ i $\hat{\beta}_i$. Takvu regresiju, u kojoj se povrat pojedine imovine kroz vrijeme regresira na faktore, nazivamo *vremenskom regresijom*

(engl. time series regression).

Vremenska regresija daje procjene izloženosti $\hat{\beta}_i$ za sve imovine. Time ostaje neprocijenjena još samo druga skupina veličina: premije na rizik λ , za čije je metode procjene posvećen sljedeći odjeljak.

2.6. Metode procjene premija na rizik

Kako su kod Fama-French faktora premije jednake očekivanjima faktora, $\lambda_k = E(F_k)$ (odjeljak 2.3.), procjena λ svodi se na procjenu očekivanih povrata faktora. U ovom odjeljku iznosimo nekoliko pristupa toj procjeni. Svaki od njih daje vlastitu procjenu $\hat{\lambda}$, iz koje slijedi predviđeni očekivani povrat imovine iznad bezrizične stope. Tu procjenu očekivanja označavamo s $\hat{\mu}_i$,

$$\hat{\mu}_i = \hat{E}(R_i) = \hat{\beta}_i^\top \hat{\lambda}. \quad (2.15)$$

2.6.1. Procjena povijesnom sredinom

Najjednostavniji način procjene očekivanja bilokoje veličine jest njezin prosjek u uzorku. Budući da je premija faktora upravo njegovo očekivanje, prirodno je procijeniti je prosjekom opaženih povijesnih povrata faktora,

$$\hat{\lambda}^{\text{pov}} = \frac{1}{T} \sum_{t=1}^T F_t, \quad (2.16)$$

gdje su $F_1, \dots, F_T$ povrati faktora u T razdoblja raspoloživih u trenutku procjene. Premija se svakog faktora time procjenjuje njegovim povijesnim prosječnim povratom.

Pristup je intuitivan i ne uvodi nikakve dodatne pretpostavke, pa služi kao temeljna osnova s kojom uspoređujemo ostale metode. Njegova je slabost što pretpostavlja da je premija kroz vrijeme stalna. Budući da su financijski povrati vrlo šumoviti, a premije se mijenjaju kroz vrijeme, povijesni prosjek može dati nestabilnu i pristranu procjenu, što upravo motivira složenije pristupe koji slijede.

2.6.2. Procjena s poznatim budućim faktorima (engl. *oracle*)

Povijesni prosjek koristi samo podatke poznate u trenutku procjene. Da bismo odvojili pogrešku koja potječe od *procjene premija* od pogreške koja potječe od samog modela, uvodimo idealiziranu (engl. *oracle*) procjenu koja namjerno koristi informaciju nedostupnu u stvarnosti.

Umjesto povijesnih povrata, oracle procjenjuje premije prosjekom povrata faktora upravo u budućem razdoblju za koje se predviđa,

$$\hat{\lambda}^{\text{ora}} = \frac{1}{H} \sum_{h=1}^H F_{t+h}, \quad (2.17)$$

gdje su $F_{t+1}, \dots, F_{t+H}$ povrati faktora u razdoblju predviđanja duljine H . Drugim riječima, oracle procjenjuje premije *gledajući u budućnost*, kao da već u trenutku procjene savršeno poznaje buduće povrate faktora. Iz tog razloga to nije ostvariva metoda predviđanja, nego savršeno informirana idealizacija koja nam služi isključivo kao mjerilo.

Njegova je svrha referentna. Oracle daje najbolju procjenu koju bi bilo koja druga metoda procjene λ mogla postići uz dane izloženosti $\hat{\beta}_i$, jer uklanja svaku pogrešku u procjeni premija. Preostala pogreška predviđanja tada dolazi isključivo iz ograničenja modela: nesavršenih izloženosti i idiosinkratskog šuma. Time oracle služi kao *gornja granica izvedbe*, a razlika između izvedbe ostvarive metode i oraclea mjeri koliko nas stvarno košta to što premije moramo procjenjivati.

2.6.3. Fama-MacBeth regresija

Povijesni prosjek i oracle premije procjenjuju izravno iz povrata samih faktora. Fama-MacBeth regresija (Fama i MacBeth, 1973) ide drukčijim putem: premije procjenjuje iz *presjeka povrata imovina*. U svakom razdoblju ispituje koliku je nagradu tržište toga mjeseca stvarno platilo po jedinici izloženosti svakom faktoru, a zatim te nagrade usrednjuje kroz vrijeme. Postupak se provodi u dva koraka.

Prvi korak (vremenska regresija). Za svaku imovinu procijenimo njezine faktorske izloženosti $\hat{\beta}_i$ vremenskom regresijom povrata iznad bezrizične stope na faktore, upravo postupkom iz odjeljka 2.5.2. Rezultat su procijenjene izloženosti svih imovina.

Drugi korak (presječna regresija). U svakom razdoblju t regresiramo *presjek* povrata iznad bezrizične stope svih N imovina na njihove procijenjene izloženosti,

$$R_{i,t} = \gamma_{t,0} + \gamma_{t,1}\hat{\beta}_{i,1} + \cdots + \gamma_{t,m}\hat{\beta}_{i,m} + e_{i,t}, \quad i = 1, \dots, N. \quad (2.18)$$

Sada su izloženosti $\hat{\beta}_i$ poznati regresori, a nepoznati su koeficijenti $\gamma_{t,k}$. Nagib $\gamma_{t,k}$ mjeri dodatni povrat koji je u razdoblju t pripadao jedinici veće izloženosti faktoru k , dakle povrat (premiju) faktora k ostvaren u tom razdoblju; odsječak $\gamma_{t,0}$ je dio povrata nepovezan s izloženostima. Ponavljanjem te presječne regresije u svakom razdoblju dobivamo vremenski niz procijenjenih povrata faktora $\gamma_t = (\gamma_{t,1}, \dots, \gamma_{t,m})$.

Procjena premija. Premiju svakog faktora napokon procjenjujemo prosjekom njegovih povrata kroz svih T razdoblja,

$$\hat{\lambda}^{\text{FM}} = \bar{\gamma} = \frac{1}{T} \sum_{t=1}^T \gamma_t, \quad \bar{\gamma}_k = \frac{1}{T} \sum_{t=1}^T \gamma_{t,k}. \quad (2.19)$$

Obje regresije, vremenska i presječna, provode se metodom najmanjih kvadrata iz odjeljka 2.5.1. Za razliku od povijesne sredine, koja koristi samo povrate faktora, Fama-MacBeth premije izvlači iz povezanosti izloženosti i povrata kroz cijeli skup imovina. Ako model dobro objašnjava prosječne povrate, prosječni odsječak $\bar{\gamma}_0$ trebao bi pritom biti blizak nuli, u skladu s restrikcijom $\alpha_i = 0$ iz odjeljka 2.3.

2.7. Procjena premija dubokim učenjem

Metode iz prethodnog odjeljka premije procjenjuju jednostavnim prosjekom ili regresijom. Uvedimo sada pristup zasnovan na dubokom učenju, koji premije nastoji *predvidjeti* iz nedavne povijesti faktora pomoću povratne neuronske mreže. Najprije ukratko opisujemo samu mrežu, a zatim način na koji je koristimo za procjenu premija.

2.7.1. Povratne mreže i LSTM

Neuronska mreža je parametrizirana funkcija koja iz ulaza računa izlaz, a iz podataka uči prilagodbom svojih parametara. Podaci u ovom radu su vremenski niz, slijed povrata faktora, u kojem redoslijed nosi informaciju, pa je potrebna mreža koja taj slijed obra-

đuje uvažavajući prošlost. Takvo svojstvo ima *povratna neuronska mreža* (engl. *recurrent neural network*, RNN). Ona niz obrađuje korak po korak i u svakom trenutku t održava *skriveno stanje* $h^{(t)}$ koje sažima dotad viđeno,

$$h^{(t)} = f(h^{(t-1)}, x^{(t)}), \quad (2.20)$$

gdje je $x^{(t)}$ ulaz u trenutku t . Skriveno se stanje prenosi iz koraka u korak, pa mreža u kasnijim koracima može koristiti informaciju iz ranijih.

Povratna ćelija s dugoročnom memorijom (engl. *long short-term memory*, LSTM) poteškoće rješava tako da odvoji *stanje ćelije* $c^{(t)}$, koje služi kao memorija, od skrivenog stanja $h^{(t)}$ iz kojeg se računa izlaz (Goodfellow et al., 2016, pogl. 10.10). Stanje ćelije ažurira se zbrajanjem, bez množenja matricom, čime se izbjegava opisani problem:

$$c^{(t)} = f^{(t)} \odot c^{(t-1)} + i^{(t)} \odot \hat{c}^{(t)}, \quad (2.21)$$

gdje je $\hat{c}^{(t)}$ *doprinos stanju ćelije* izračunat iz trenutnog ulaza i prethodnog skrivenog stanja, a $\odot$ označava množenje po elementima (Hadamardov produkt).

Veličine $f^{(t)}$ i $i^{(t)}$ su *vrata* (propusnice) koje filtriraju informaciju: svaka je vektor vrijednosti u intervalu $(0, 1)$, dobiven sigmoidnom funkcijom, koji određuje koliki se dio informacije propušta. *Vrata zaboravljanja* $f^{(t)}$ određuju koliki se dio prethodnog stanja ćelije zadržava, a *ulazna vrata* $i^{(t)}$ koliki se dio novog doprinosa $\hat{c}^{(t)}$ dodaje. Naposljetku, skriveno stanje računamo iz stanja ćelije pomoću *izlaznih vrata* $o^{(t)}$,

$$h^{(t)} = o^{(t)} \odot \tanh(c^{(t)}). \quad (2.22)$$

Razdvajanjem memorije $c^{(t)}$ od izlaza $h^{(t)}$, zbrajajućim ažuriranjem stanja ćelije i trima vratima koja filtriraju informaciju, LSTM zadržava važnu informaciju kroz dulje nizove i izbjegava nestajuće i eksplodirajuće gradijente. Upravo ga ta sposobnost rada s dugim vremenskim nizovima čini prikladnim za procjenu faktorskih premija iz njihove povijesti, čemu se okrećemo u nastavku.

2.7.2. Procjena premija LSTM mrežom

Posljednja metoda zasniva se na LSTM mreži iz prethodnog odjeljka. Umjesto da premije procjenjujemo prosjekom proteklih povrata, učimo mrežu da ih predviđa iz nedavne povijesti faktora: kao ulaz joj dajemo niz proteklih vrijednosti faktora, a ona kao izlaz daje procjenu premija $\hat{\lambda}^{\text{LSTM}}$, iz koje predviđeni očekivani povrat iznad bezrizične stope slijedi kao i prije, $\hat{\mu}_i = \hat{\beta}_i^T \hat{\lambda}^{\text{LSTM}}$.

Parametre mreže učimo na povijesnim podacima, tako da njezina predviđanja što bolje odgovaraju stvarno ostvarenim povratima faktora. Za razliku od povijesne sredine, koja svim razdobljima pridružuje istu, fiksnu vrijednost, LSTM može objasniti vremensku promjenjivost i obrasce u kretanju faktora koje jednostavan prosjek zanemaruje. Konkretni oblik ulaza i postupak učenja iznosimo zajedno s eksperimentalnim dizajnom u nastavku rada.

3. Podaci

Da bismo metode procjene premija iz prethodnog poglavlja primijenili na pravim podacima i međusobno ih usporedili, potrebni su povijesni tržišni podaci. U ovom poglavlju opisujemo korištene podatke: imovinu čije povrate nastojimo objasniti, faktore, bezrizičnu stopu te dodatnu makroekonomsku varijablu koju kasnije koristimo. Za svaki izvor navedeno je odakle potječe i koje razdoblje pokriva, te se opisuje postupak kojim su pojedini skupovi pripremljeni i spojeni u jedinstven skup za analizu.

3.1. Izvori i razdoblje uzorka

Podaci su preuzeti iz dvaju javno dostupnih izvora. Prvi je skup podataka Kennetha Frencha (French, 2024), iz kojeg preuzimamo povrate imovine čije ponašanje objašnjavamo, vrijednosti faktora te bezrizičnu stopu. Drugi je javno dostupna baza Roberta Shillera, iz koje preuzimamo makroekonomsku varijablu opisanu kasnije u poglavlju.

Sve veličine promatramo na *mjesečnoj* razini, pa jedno razdoblje odgovara jednom mjesecu, u skladu s oznakama uvedenima u odjeljku 2.1. Povrati su izraženi u postotcima. Uzorak obuhvaća razdoblje od siječnja 1970. do veljače 2026. godine, ukupno 674 mjeseca. Početak u 1970. godini biramo jer od tada nadalje sve tri skupine podataka (povrati imovine, faktori i makroekonomska varijabla) istodobno postoje i nemaju praznina, te nakon njihova pridruživanja dobivamo neprekinut vremenski niz bez nedostajućih vrijednosti. Na tako dobivenom skupu podataka provode se procjene svakom od definiranih metoda.

3.2. Promatrana imovina

Model primjenjujemo na skupu imovina čije povrate želimo objasniti, a koji nazivamo promatranom imovinom. Na njoj kasnije ocjenjujemo koliko su pojedine metode procjene premija uspješne. U ovom radu tu imovinu čini 49 industrijskih portfelja preuzetih iz skupa podataka Kennetha Frencha.


Industrijski portfelji nastaju tako da se svaka kompanija na američkom tržištu, na temelju svoje glavne djelatnosti, svrsta u jednu od 49 industrija (primjerice bankarstvo, rudarstvo ili proizvodnja hrane). Sve kompanije iste industrije potom tvore jedan portfelj, čiji mjesečni povrat promatramo. Riječ je o portfeljima u kojima su težine određene tržišnom kapitalizacijom. Unutar svakog portfelja pojedina kompanija sudjeluje proporcionalno svojoj tržišnoj veličini, pa veće kompanije imaju veću težinu. To je upravo težinski prosjek povrata uveden u odjeljku 2.1., samo što težine ovdje nisu jednake, nego odražavaju tržišnu kapitalizaciju.

Tako dobivamo 49 vremenskih nizova mjesečnih povrata, svaki za po jednu industriju, koje pratimo kroz cijelo razdoblje uzorka. U skladu s definiranim u odjeljku 2.1., i ovdje radimo s povratima iznad bezrizične stope, pa od povrata svakog portfelja oduzimamo bezrizičnu stopu istoga mjeseca.

Industrijske portfelje bираmo kao testnu imovinu jer pružaju širok presjek tržišta: obuhvaćaju različite gospodarske sektore, koji se međusobno razlikuju po osjetljivosti na faktore, pa daju raznolike izloženosti na kojima model dolazi do izražaja. Jednako je važno da nisu oblikovani prema istim obilježjima na kojima počivaju sami faktori (veličini i omjeru knjigovodstvene i tržišne vrijednosti), pa procjena nije unaprijed prilagođena faktorima i njihova je uspješnost bolje provjerena. Raznolikost prosječnih povrata među industrijama prikazana je na slici 3.1.: prosječni mjesečni povrat iznad bezrizične stope kreće se od 0,24 % do 1,06 %, što potvrđuje da različite industrije imaju značajno različite prosječne povrate.

3.3. Faktori i bezrizična stopa

U radu koristimo tri Fama-French faktora (tržišni MKT, SMB i HML) uvedena u odjeljku 2.4.2. Sva tri faktora, kao i bezrizičnu stopu, preuzimamo iz skupa podataka Kennetha Frencha.



Slika 3.1. Prosječni mjesečni povrat iznad bezrizične stope za svaku od 49 industrija, poredan po veličini.

cha. Izraženi su u postocima na mjesečnoj razini, jednako kao povrati promatrane imovine.

Tržišni faktor MKT je povrat iznad bezrizične stope za vrlo široki tržišni portfelj, dakle težinski povrat zasnovan na tržišnoj kpaitalizaciji svih promatranih kompanija umanjen za bezrizičnu stopu. Bezrizična stopa R_f , uvedena u odjeljku 2.1., ovdje je konkretno prinos jednomjesečnih američkih državnih trezorskih zapisa, preuzet iz istog izvora.

Faktori SMB i HML grade se iz povrata šest pomoćnih portfelja dobivenih dvostrukim poduzeća (Fama i French, 1993). Kompanije se najprije po tržišnoj kapitalizaciji dijele u dvije skupine, malu (S) i veliku (B), a zatim po omjeru knjigovodstvene i tržišne

vrijednosti u tri skupine: nisku (L), srednju (M) i visoku (H). Primjenom navedenih podjela nastaje šest portfelja, koje označavamo prema pripadnoj skupini po veličini i po omjeru, primjerice $R_{S,H}$ za povrat portfelja malih poduzeća s visokim omjerom. SMB faktor definiran je kao razlika prosječnog povrata triju portfelja malih poduzeća i prosječnog povrata triju portfelja velikih poduzeća,

$$\text{SMB} = \frac{1}{3}(R_{S,L} + R_{S,M} + R_{S,H}) - \frac{1}{3}(R_{B,L} + R_{B,M} + R_{B,H}), \quad (3.1)$$

dok je HML faktor razlika prosječnog povrata dvaju portfelja s visokim omjerom i prosječnog povrata dvaju portfelja s niskim omjerom,

$$\text{HML} = \frac{1}{2}(R_{S,H} + R_{B,H}) - \frac{1}{2}(R_{S,L} + R_{B,L}). \quad (3.2)$$

Time obje razlike, u skladu s odjeljkom 2.4.2., izoliraju željeni učinak: SMB razliku po veličini, a HML razliku po omjeru knjigovodstvene i tržišne vrijednosti.

Osnovnu deskriptivnu statistiku triju faktora kroz razdoblje uzorka prikazuje tablica 3.1. Tržišni faktor ima najveću prosječnu vrijednost, ali i najveću varijabilnost, dok su SMB i HML faktor u prosjeku manji. Korelacije među faktorima su male, što je u ovom slučaju poželjno, jer pokazuje da je svaki faktor zaseban izvor različite informacije.


Tablica 3.1. Deskriptivna statistika mjesečnih faktora kroz razdoblje iz uzorka: srednja vrijednost i standardna devijacija (u postocima) te međusobne korelacije.

Faktor	Aritmetička sredina (%)	St. dev. (%)	Korelacije		
			MKT	SMB	HML
MKT	0,618	4,569	1,00	0,28	−0,22
SMB	0,080	3,041	0,28	1,00	−0,15
HML	0,305	3,073	−0,22	−0,15	1,00

Kako bismo prikazali dugoročno ponašanje triju faktora kroz promatrano razdoblje, njihovo kumulativno kretanje prikazujemo na slici 3.2.

3.4. Shillerov omjer cijene i zarade

Uz faktore i bezrizičnu stopu, u analizu uvodimo i makroekonomsku varijablu koja opisuje prilagođeni odnos tržišne kapitalizacije kompanije i njene neto prihode. Riječ je o



Slika 3.2. Kumulativni zbroj mjesečnih povrata triju faktora kroz razdoblje uzorka. Svaka krivulja pokazuje povrate pojedinog faktora od početka razdoblja do trenutka t . Pokazuje razinu premije i njezinu promjenjivost kroz vrijeme.

višku CAPE prinosa (engl. *excess CAPE yield*, ECY), veličini izvedenoj iz Shillerova CAPE pokazatelja, koju preuzimamo iz Shillerove mrežne baze podataka (Shiller, 2024).

CAPE (engl. *cyclically adjusted price-to-earnings ratio*) jest omjer cijene i zarade prilagođen poslovnom ciklusu. Za razliku od običnog omjera cijene i zarade, koji u nazivniku ima zaradu jedne godine, CAPE u nazivniku uzima prosjek realne zarade kroz proteklih deset godina (Shiller, 2024). Formalno, uz realnu cijenu P i realnu zaradu E_j ostvarenu u godini j od proteklih deset, CAPE je


$$\text{CAPE} = \frac{P}{\frac{1}{10} \sum_{j=1}^{10} E_j}. \quad (3.3)$$

Usrednjavanjem zarade kroz desetogodišnji prozor uklanja se utjecaj kratkoročnih varijacija povezanih s poslovnim ciklusom, pa CAPE daje stabilniju mjeru relativne vrijednosti tržišta u odnosu na njegovu profitabilnost. Njegova recipročna vrijednost, $1/\text{CAPE}$, predstavlja ciklički prilagođen *prinos od zarade*, odnosno procjenu prinosa koji dionice ostvaruju u odnosu na uloženu cijenu.

Višak CAPE prinosa zatim je razlika između spomenutog prinosa i realne (za inflaciju prilagođene) dugoročne kamatne stope. Na taj način on mjeri koliko se više od ulaganja u dionice očekuje u odnosu na relativno sigurne dugoročne obveznice, pa služi

kao pokazatelj očekivanog povrata dionica iznad bezrizične stope zasnovan na vrednovanju tržišta. Naglašavamo da je kamatna stopa koja ovdje ulazi u izračun dugoročna realna stopa, različita od kratkoročne bezrizične stope R_f iz odjeljka 2.1. Obje se odnose na sigurne prinose, ali se razlikuju po dospijeću i ulozi u modelu.

Za razliku od faktora, ova varijable ne ulazi u sam faktorski model, već ju koristimo kao dodatni ulaz pri procjeni premija dubokim učenjem (odjeljak 2.7.). Time mreži uz povijest samih faktora dajemo i širu informaciju o trenutnoj precijenjenosti ili podcijenjenosti tržišta, dok klasične metode procjene tu varijablu ne upotrebljavaju. Vrijednost je dostupna na mjesečnoj razini kroz cijelo razdoblje iz uzorka. Njezino kretanje, zajedno s bezrizičnom stopom, prikazano je na slici 3.3. Vidljivo je da višak CAPE prinosa osjetno varira kroz vrijeme, za razliku od male i gotovo konstantne bezrizične stope, pa možemo reći da nosi informaciju o promjenjivoj razini vrednovanja tržišta koju sama bezrizična stopa ne daje.



Slika 3.3. Višak CAPE prinosa (ECY) i bezrizična stopa R_f kroz razdoblje uzorka, obje na mjesečnoj razini u postocima.

3.5. Obrada

Prije analize početne podatke iz pojedinih izvora dovodimo u upotrebljiv oblik. Svaki niz svodimo na mjesečnu vrijednost s datumom na kraju mjeseca, a vrijednosti koje ukazuju na nedostajuće podatke posebno označavamo. Sve izvore zatim ograničavamo na zajednički vremenski raspon: zadržavamo samo razdoblja od siječnja 1970. godine nadalje, u

kojima istodobno postoje povrati imovine, faktori, bezrizična stopa i makroekonomska varijabla. Time dobivamo jedinstven skup bez praznina.

Iz povrata svakog portfelja oduzimamo bezrizičnu stopu istoga mjeseca kako bismo dobili povrate iznad bezrizične stope, u skladu s odjeljkom 2.1. Višak CAPE prinosa pritom izražavamo u postocima, na istoj skali kao i ostale povrate.

4. Rezultati

U ovom poglavlju metode procjene premija iz prethodnih poglavlja primjenjujemo na opisanim podacima te ih međusobno uspoređujemo. Najprije iznosimo postupak kojim provodimo metode, zatim mjere kojima ocjenjujemo uspješnost, a potom rezultate triju klasičnih metoda i metode zasnovane na dubokom učenju, koje naposljetku međusobno uspoređujemo.

4.1. Klizni vremenski prozor

Cilj naime nije objasniti prošle povrate, nego predvidjeti buduće: metoda koja dobro opisuje upravo ono razdoblje na kojem je trenirana, a loše predviđa izvan njega, nije primjenjiva. Zato procjenu i provjeru razdvajamo u vremenu, postupkom koji nazivamo *kliznim vremenskim prozorom*.

Klizni prozor radi na sljedeći način. U svakom koraku promatramo 60 uzastopnih mjeseci koje zovemo *razdobljem procjene*, te 12 mjeseci koji neposredno slijede i čine *razdoblje predviđanja*. Na razdoblju procjene procjenjujemo parametre modela, a na razdoblju predviđanja, koje pri procjeni nije korišteno, provjeravamo koliko su predviđanja točna. Potom cijeli prozor pomičemo za jedan mjesec naprijed i postupak ponavljamo, sve dok ne iscrpimo uzorak. Tako nastaje velik broj predviđanja, svako za drugo razdoblje, na temelju kojih metode možemo pouzdano usporediti. Budući da se razdoblje predviđanja uvijek nalazi nakon razdoblja procjene, riječ je o *out-of-sample* provjeri.

Unutar svakog koraka za sve metode postupamo jednako. Najprije za svaku od 49 industrija procjenjujemo njezine faktorske izloženosti, i to vremenskom regresijom njezinih povrata iznad bezrizične stope na faktore kroz 60 mjeseci razdoblja procjene, kako je opisano u odjeljku 2.5.2. Zatim premije na rizik procjenjujemo jednom od metoda iz

odjeljaka 2.6. i 2.7. Predviđeni povrat iznad bezrizične stope za industriju i tada je

$$\hat{\mu}_i = \hat{\beta}_i^\top \hat{\lambda}, \quad (4.1)$$

umnožak procijenjenih izloženosti i procijenjenih premija. Predviđanje ne sadrži odsječak α_i : prema definiranom u 2.3., očekivani se povrat iznad bezrizične stope u potpunosti svodi na izloženost faktorima i njihove premije, stoga pri predviđanju uzimamo $\alpha_i = 0$.

Kao ishod uzimamo prosječni povrat iznad bezrizične stope te industrije kroz 12 mjeseci razdoblja predviđanja. Tu veličinu nazivamo realiziranim povratom i s njom uspoređujemo predviđanja. Razlika između predviđenog i realiziranog povrata, prikupljena preko svih industrija i svih položaja prozora, osnova je za mjere uspješnosti koje uvodimo u nastavku.

4.2. Mjere uspješnosti

Predviđanja ocjenjujemo prema tome koliko su blizu realiziranim povratima. Označimo s $r_{i,w}$ realizirani, a s $\hat{r}_{i,w}$ predviđeni povrat iznad bezrizične stope industrije i u prozoru w , te neka je N ukupan broj takvih povrata, uključujući sve industrije i sve položaje kliznog prozora. Uspješnost mjerimo na dva načina.

Prva je mjera *srednja kvadratna pogreška* (engl. *mean squared error*, MSE), prosjek kvadrata odstupanja predviđanja od realiziranog povrata,

$$\text{MSE} = \frac{1}{N} \sum_{i,w} (r_{i,w} - \hat{r}_{i,w})^2. \quad (4.2)$$

Kvadriranjem sve pogreške postaju pozitivne, a one veće se više kažnjavaju. Manja vrijednost MSE-a stoga dolazi iz boljih predviđanja.

Druga je mjera *koeficijent determinacije* R^2 , koji uspješnost metode stavlja u odnos prema jednostavnom nul-modelu. Nul-model je predviđanje koje bi za svaku industriju jednostavno upotrijebilo njezin vlastiti prosječni realizirani povrat $\bar{r}_i$ kroz cijelo razdob-

lje. Koeficijent determinacije tada je

$$R^2 = 1 - \frac{\sum_{i,w} (r_{i,w} - \hat{r}_{i,w})^2}{\sum_{i,w} (r_{i,w} - \bar{r}_i)^2}. \quad (4.3)$$

U brojniku je zbroj kvadrata pogrešaka metode, a u nazivniku zbroj kvadrata odstupanja realiziranih povrata od već spomenutog. Ako su pogreške metode jednake onima iz nazivnika, $R^2 = 0$: metoda nije bolja od jednostavnog predviđanja vlastitim prosjekom svake industrije. Pozitivan R^2 govori da metoda nadmašuje to mjerilo, a što je bliži vrijednosti 1, predviđanja su točnija. Budući da svaku industriju uspoređujemo s njezinom vlastitom prosječnom razinom povrata, razlike u prosječnim povratima među industrijama ne utječu na rezultat.

4.3. Rezultati klasičnih metoda procjene

U kliznom prozoru iz odjeljka 4.1. najprije primjenjujemo tri klasične metode procjene premija opisane u odjeljku 2.6.: procjenu povijesnom sredinom, oracle i Fama-MacBeth regresiju. Podsjećamo da oracle metoda premije procjenjuje iz prosjeka faktora na samom razdoblju predviđanja, te gleda u budućnost i nije primjenjiv u praktičnoj primjeni. Uzimamo ga kao idealiziranu gornju granicu uspješnosti. Provjeru provodimo na cijelom skupu izvanuzorkovnih predviđanja, koji obuhvaća 602 položaja prozora i ukupno 29 498 predviđanja.

Koeficijent determinacije R^2 i MSE svake metode prikazuje tablica 4.1. Rezultati su očekivano loši: obje primjenjive metode, povijesna sredina i Fama-MacBeth regresija, imaju negativan R^2 , što znači da predviđaju lošije od nul-modela, vlastitog prosjeka svake industrije. Jedino oracle postiže osjetno pozitivan R^2 i najmanji MSE. Drugim riječima, ni povijesna sredina ni Fama-MacBeth regresija ne uspijevaju unaprijed pogoditi premije bolje od jednostavnog prosjeka, dok to uspijeva tek procjena koja se služi budućim podacima. Dobiveni rezultati potvrđuju koliko je procjena premija težak problem, što je i polazna motivacija ovog rada.

Slabost procjena vidljiva je i na prikazu 4.1., koji za svaki od tri faktora uspoređuje procjene povijesne sredine i Fama-MacBeth regresije s oracle vrijednošću. Kad bi pro-

Tablica 4.1. Koeficijent determinacije R^2 i MSE triju klasičnih metoda na cijelom skupu out-of-sample predviđanja (602 prozora, 29 498 predviđanja).

Metoda	R^2	MSE
povijesna sredina	-0,229	4,386
oracle	0,455	1,947
Fama-MacBeth	-0,337	4,773

cjene bile točne, točke bi ležale na isprekidanom pravcu jednakosti. Umjesto toga, široko su raspršene, što pokazuje da procijenjene premije slabo prate stvarno ostvarene vrijednosti.

Slika 4.2. prikazuje R^2 zasebno za svaku od 49 industrija. Obrazac je jasan: oracle postiže pozitivan R^2 u gotovo svim industrijama, dok su povijesna sredina i Fama-MacBeth regresija negativni gotovo posvuda. Razlika među dvjema primjenjivim metodama ide u korist povijesne sredine, koja je u većini industrija bolja od Fama-MacBeth regresije.


Ostaje pitanje može li metoda zasnovana na dubokom učenju nadmašiti ove klasične pristupe i približiti se gornjoj granici koju postavlja oracle, čime se bavimo u nastavku.

4.4. Procjena dubokim učenjem


Posljednju metodu gradimo na LSTM mreži iz odjeljka 2.7. Za razliku od triju klasičnih metoda, koje premije dobivaju izravnim računom iz prozora, ovdje mrežu *učimo* da premije predviđa iz nedavne povijesti.

Ulaz mreže je niz od 60 mjeseci, koliko traje i razdoblje procjene, a u svakom mjesecu sadrži pet vrijednosti: tri faktora te dvije dodatne varijable, makroekonomsku varijablu ECY i bezrizičnu stopu (odjeljci 3.3. i 3.4.). Izlaz su tri procijenjene premije $\hat{\lambda}^{\text{LSTM}} = (\hat{\lambda}_{\text{MKT}}, \hat{\lambda}_{\text{SMB}}, \hat{\lambda}_{\text{HML}})$, iz kojih predviđeni povrat iznad bezrizične stope slijedi kao i kod ostalih metoda, $\hat{\mu}_i = \hat{\beta}_i^T \hat{\lambda}^{\text{LSTM}}$, prema jednadžbi (4.1). Samu mrežu čini jedan LSTM sloj sa šesnaest jedinica i ugrađenim *ispadanjem* (engl. *dropout*, stopa 0,3), koje tijekom učenja nasumično privremeno isključuje dio jedinica i tako smanjuje sklonost prenaučivosti, te naposljetku potpuno povezani sloj koji daje tri premije.

Ovako jednostavnu mrežu odabrali smo nakon što smo isprobali i složenije arhitekture, s više slojeva i s više jedinica po sloju. Pokazalo se da jednostavniji modeli uče bolje:



Slika 4.1. Procjene faktorskih premija povijesnom sredinom i Fama-MacBeth regresijom naspram oracle vrijednosti, zasebno po faktoru. Svaki položaj prozora daje po jednu točku za svaku metodu; isprekidani pravac označava savršeno poklapanje procjene i oracle vrijednosti.



Slika 4.2. Koeficijent determinacije R^2 po pojedinoj od 49 industrija za tri klasične metode.


što je mreža bila složenija, to je prenaučенost postajala veći problem, pa bi takav model dobro opisivao podatke za učenje, a slabije generalizirao na novima. Zbog toga smo se zadržali na maloj mreži s jednim LSTM slojem.

Mrežu učimo na način da joj parametre postupno variramo kako bi predviđeni povrati što bolje odgovarali realiziranim. Mjeru koju pritom nastojimo smanjiti nazivamo gubitkom. U ovom slučaju to je srednja kvadratna pogreška između predviđenog i realiziranog povrata, ista veličina kao u jednadžbi (4.2). Parametre podešavamo u koracima koje zovemo *epohama*: u svakoj epohi mreža jednom prođe kroz sve podatke za učenje i malo izmjeni parametre, koristeći optimizacijski postupak Adam uz malu stopu učenja,

podatke podijeljene u serije od po 16 primjera i najviše 500 epoha.

Prozore dijelimo kronološki u tri dijela: prvih 75 % služi za *učenje* (451 prozor), sljedećih 15 % za *validaciju* (90 prozora), a preostali dio za *ispitivanje* (61 prozor, počevši od 2020.). Podjela je kronološka, a ne nasumična, kako mreža nikad ne bi učila na razdoblju kasnijem od onoga na kojem je poslije ispitujemo. Gubitak izračunat na skupu za učenje zovemo *trening gubitkom*, a onaj na validacijskom skupu *validacijskim gubitkom*: prvi pokazuje koliko se mreža prilagodila podacima koje je vidjela, a drugi koliko dobro poopćava na podatke koje pri učenju nije koristila.

Učenje pratimo kroz epohe i primjenjujemo *rano zaustavljanje*: čim validacijski gubitak prestane padati i ne popravi se tijekom određenog broja uzastopnih epoha, učenje prekidamo i vraćamo parametre iz epohe s najmanjim validacijskim gubitkom. Time sprječavamo da predugo učenje mrežu previše prilagodi podacima za učenje na štetu poopćavanja. Slika 4.3. prikazuje oba gubitka kroz epohe. Validacijski gubitak naglo pada u prvim epohama, a zatim se stabilizira. Rano zaustavljanje odabire najbolju epohu (ovdje 192.).



Slika 4.3. Trening i validacijski gubitak (srednja kvadratna pogreška) kroz epohe učenja LSTM mreže. Okomita isprekidana crta označava epohu s najmanjim validacijskim gubitkom, koja je određena naglim zaustavljanjem.

Tako naučenu mrežu primjenjujemo na ispitnom skupu, a njezina predviđanja u nastavku uspoređujemo s klasičnim metodama.

4.5. Usporedba metoda i rasprava

Da bismo sve metode usporedili na istim podacima, ocjenjujemo ih na ispitnom skupu (posljednjem 61 prozoru, počevši od 2020. godine) na kojem jedino i postoje predviđanja LSTM modela. Tablica 4.2. prikazuje R^2 i MSE svih četiriju metoda.

Tablica 4.2. Skupni koeficijent determinacije R^2 i MSE na ispitnom skupu (61 prozor od početka 2020., 2989 predviđanja) za sve četiri metode.


Metoda	R^2	MSE
povijesna sredina	-0,348	5,248
oracle	0,380	2,415
Fama-MacBeth	-0,579	6,146
LSTM	-0,141	4,442

Među trima primjenjivim metodama model dubokog učenja pokazuje se kao najbolji: ima najviši R^2 i najmanji MSE, ispred povijesne sredine i osjetno ispred Fama-MacBeth regresije, koja je na ovom razdoblju najslabija. Mreža dakle uspijeva premije predvidjeti bolje od obiju klasičnih primjenjivih metoda. Ipak, njezin je R^2 i dalje negativan, pa ni ona ne nadmašuje jednostavni nul-model, a od idealizirane gornje granice koju postavlja oracle ostaje znatno udaljena.


Slika 4.4. uspoređuje procjene povijesne sredine i LSTM modela s oracle vrijednošću, po faktoru. Procjene su kod obiju metoda široko raspršene oko pravca jednakosti, pa prednost LSTM modela nije toliko u vizualnom poklapanju s oracle vrijednošću koliko u manjoj ukupnoj pogrešci predviđanja.

Da prednost LSTM modela nije proizašla samo iz agregacije po industrijama, slika 4.5. prikazuje MSE po pojedinoj industriji. Kod većine industrija LSTM model ima manju pogrešku od povijesne sredine i Fama-MacBeth regresije, dok oracle očekivano ima najmanju; obrazac je vrlo jasan kroz cijeli presjek industrija.

Rezultati pokazuju da duboko učenje donosi postojano, premda umjereno, poboljšanje nad klasičnim primjenjivim metodama procjene premija. Takvi rezultati održavaju početnu tvrdnju rada da metode strojnog učenja mogu bolje iskoristiti obrasce u povijesti faktora nego jednostavan prosjek. Istodobno, činjenica da niti jedna primjenjiva metoda ne postiže pozitivan R^2 , kao i velik razmak do oracle vrijednosti, potvrđuju koliko je predviđanje premija težak problem: financijski su podaci izrazito šumoviti, premije se



Slika 4.4. Procjene faktorskih premija povijesnom sredinom i LSTM modelom naspram oracle vrijednosti, zasebno po faktoru, na ispitnom skupu. Isprekidani pravac označava savršeno poklapanje procjene i oracle vrijednosti.



Slika 4.5. Srednja kvadratna pogreška na ispitnom skupu po pojedinoj od 49 industrija za sve četiri metode, poredana po vrijednosti za LSTM model.

mijenjaju kroz vrijeme, a ispitno razdoblje, koje obuhvaća turbulentne godine od 2020. nadalje, dodatno otežava predviđanje. Velik razmak do oracle granice ujedno pokazuje da u podacima ostaje znatan dio predvidljive informacije koji nijedna od razmatranih metoda ne uspijeva u potpunosti iskoristiti.

5. Zaključak

Procjena premija na rizik najosjetljiviji je korak u primjeni faktorskih modela: o njoj većinski ovisi koliko dobro model predviđa buduće povrate, a klasične su procjene često nepouzdana. U ovom je radu ispitano može li metoda strojnog učenja dati bolju procjenu premija od klasičnih pristupa. Na primjeru Fama-French trofaktorskog modela i 49 industrijskih portfelja kao testne imovine, out-of-sample usporedbom smo kliznim prozorom ocijenili četiri metode procjene premija: procjenu povijesnom sredinom, Fama-MacBeth regresiju, idealiziranu oracle procjenu kao gornju granicu te procjenu LSTM mrežom, kojoj uz povijest faktora kao ulaz služi i makroekonomska varijabla.

Rezultati pokazuju da obje primjenjive klasične metode (povijesna sredina i Fama-MacBeth regresija) ne uspijevaju predvidjeti premije bolje od jednostavnog prosjeka povrata svake industrije, pa im je koeficijent determinacije negativan. Procjena zasnovana na LSTM mreži nadmašuje obje metode, čime se potvrđuje da strojno učenje može bolje iskoristiti obrasce u povijesti faktora nego jednostavan prosjek. Ipak, ni ona ne postiže pozitivan koeficijent determinacije niti se približava idealiziranoj oracle procjeni.

Poboljšanje koje donosi duboko učenje stoga je stvarno, ali umjereno. Velik razmak između svih primjenjivih metoda i oracle granice pokazuje da u podacima ostaje znatan dio predvidljive informacije koji niti jedna od metoda ne uspijeva u potpunosti iskoristiti. Time se potvrđuje da procjena premija ostaje kompleksan problem: financijski su podaci izrazito šumoviti, a premije se mijenjaju kroz vrijeme te ih je teško pouzdano predvidjeti.

Dobivene rezultate valja promatrati uz nekoliko ograničenja. Ispitno je razdoblje razmjerno kratko i obuhvaća turbulentne godine od 2020. nadalje, korišteni je model jednostavan, a kao dodatni ulaz uzeta je samo jedna makroekonomska varijabla. Daljnji bi rad mogao krenuti u smjeru bogatijih ulaznih podataka, drugačijih arhitektura mreže ili

duljega i raznolikijega razdoblja ispitivanja, čime bi se preciznije utvrdilo u kojoj mjeri strojno učenje može unaprijediti procjenu premija na rizik.

Literatura

John H. Cochrane. *Asset Pricing*. Princeton University Press, Princeton, NJ, revised izd., 2005.

Eugene F. Fama i Kenneth R. French. Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1):3–56, 1993.

Eugene F. Fama i James D. MacBeth. Risk, return, and equilibrium: Empirical tests. *Journal of Political Economy*, 81(3):607–636, 1973.

Guanhao Feng, Jingyu He, Nicholas G. Polson, i Jianeng Xu. Deep learning in characteristics-sorted factor models. <https://arxiv.org/abs/1805.01104>, 2023. arXiv:1805.01104v7 [stat.ME].

Kenneth R. French. Data library. https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html, 2024. Pristupljeno: 8. lipnja 2026.

Ian Goodfellow, Yoshua Bengio, i Aaron Courville. *Deep Learning*. MIT Press, Cambridge, MA, 2016.

Trevor Hastie, Robert Tibshirani, i Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 izd., 2009.

Richard A. Johnson i Dean W. Wichern. *Applied Multivariate Statistical Analysis*. Pearson Education Limited, Harlow, 6 izd., 2013.

William F. Sharpe. Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3):425–442, 1964.

Robert J. Shiller. Online data: U.S. stock markets 1871–present and cape ratio. <http://www.econ.yale.edu/~shiller/data.htm>, 2024. Pristupljeno: 8. lipnja 2026.

Izjava o korištenju umjetne inteligencije

Osvrt na korištenje umjetne inteligencije: Alati umjetne inteligencije korišteni su kao sredstvo bržeg pretraživanja, pretežito pronalaska materijala za potencijalno citiranje.

Izjava o korištenju umjetne inteligencije: Potvrđujem da sam tijekom izrade ovog završnog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog korištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.

Sažetak

Procjena faktora u faktorskim modelima povrata imovina zasnovana na strojnom učenju

Damjan Crnković

Faktorski modeli objašnjavaju povrate imovine njihovom izloženosti zajedničkim izvorima rizika, pri čemu svaki faktor nosi premiju, odnosno prosječnu nagradu za preuzeti rizik. Procjena tih premija najteži je dio primjene modela jer su procjene iz povijesnih podataka često nepouzidane. U radu se ispituje mogu li metode strojnog učenja procijeniti premije bolje od klasičnih pristupa. Na povratima 49 industrijskih portfelja uspoređuju se procjena povijesnim prosjekom, Fama-MacBeth regresija i povratna ćelija s dugoročnom memorijom, uz idealiziranu procjenu koja služi kao gornja granica uspješnosti. Rezultati pokazuju da neuronska mreža nadmašuje klasične primjenjive metode, no procjena premija i dalje ostaje težak i zahtjevan zadatak.

Ključne riječi: faktorski modeli; premija na rizik; procjena premija; strojno učenje; LSTM mreža; Fama-French model; industrijski portfelji

Abstract

Machine learning based factor estimation in factor models of asset returns

Damjan Crnković

Factor models explain asset returns through their exposure to common sources of risk, where each factor carries a premium, that is, the average reward for bearing that risk. Estimating these premiums is the hardest part of applying the model, because estimates from historical data are often unreliable. This thesis examines whether machine learning methods can estimate the premiums better than classical approaches. Using the returns of 49 industry portfolios, it compares estimation by the historical average, the Fama-MacBeth regression, and a neural network with long short-term memory, together with an idealized estimate that serves as an upper bound on performance. The results show that the neural network outperforms the applicable classical methods, yet estimating the premiums remains a hard and demanding task.

Keywords: factor models; risk premium; premium estimation; machine learning; LSTM network; Fama-French model; industry portfolios